

Rubrica de Avaliação do Projeto Final

IF1014 - Mineração de Dados Aplicada com CRISP-DM

Prof. Leandro Maciel Almeida

2026.1

A nota final do projeto é calculada pela soma dos critérios abaixo, cada um avaliado em quatro níveis de desempenho. O peso total é 100%. Decisões que envolvem violação da regra de partição treino e teste (Seção) podem zerar critérios específicos.

Escala de níveis

- **Insuficiente** (0 a 0,40): item ausente, incorreto ou sem evidências.
- **Básico** (0,50 a 0,70): item presente porém superficial; faltam justificativas ou evidências robustas.
- **Bom** (0,75 a 0,90): item completo, com decisões justificadas e evidências adequadas.
- **Excelente** (0,95 a 1,00): item completo, com análise profunda, comparações pareadas e narrativa clara para o cliente.

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Business Understanding e briefing do cliente	8%	Sem briefing ou problema mal definido.	Briefing presente porém genérico, métrica não escolhida.	Briefing claro com métrica principal e restrições do cliente.	Briefing rico, com riscos éticos, custo de erro e metas mensuráveis.
Data Understanding (EDA)	10%	EDA ausente ou apenas estatísticas triviais.	EDA básica (tipos, faltantes, distribuição de classes).	EDA com correlações, outliers e narrativa interpretativa.	EDA aprofundada com evidências que orientam o pré-processamento.
Data Preparation (baseline e variantes)	12%	Pré-processamento ausente ou inconsistente.	Apenas baseline mínimo, sem variantes.	Baseline claro e ao menos duas variantes (balanceamento e escala/codificação).	Baseline e pelo menos três variantes, cada uma com justificativa em dados.
Modeling (dez algoritmos com configurações justificadas)	15%	Menos de cinco algoritmos aplicados ou sem configurações documentadas.	Dez algoritmos rodados, configurações pouco justificadas.	Dez algoritmos com configurações escolhidas a partir de evidência.	Dez algoritmos com configurações justificadas, comentários sobre tradeoffs por modelo.
Busca de hiperparâmetros e comparação entre modelos	18%	Sem busca sistemática ou sem curvas treino vs validação.	Busca rasa em parte dos modelos, comparação sem testes pareados.	Busca sistemática com curvas e comparação com Wilcoxon ou paired t-test.	Busca refinada por evidência experimental, com análise estatística robusta.
Evaluation com validação cruzada no treino	8%	Sem validação cruzada ou métricas inconsistentes.	CV simples, métricas pouco interpretadas.	CV com métricas adequadas (F1-macro, balanced accuracy) e interpretação.	Avaliação com múltiplas métricas, ROC e PR multiclasse e análise por classe.
Avaliação final única no conjunto de teste	5%	Teste tocado antes da hora ou ausente.	Teste aplicado uma vez, com relatório básico.	Teste aplicado uma vez com relatório de classificação e matriz de confusão.	Avaliação final clara, com análise por classe e comparação honesta com a CV.
Deployment (esboço de uso, riscos, monitoramento)	4%	Seção ausente.	Menção superficial a uso ou riscos.	Esboço de uso prático e principais riscos identificados.	Plano realista de uso, monitoramento e plano de retreinamento.
Justificativa experimental transversal	13%	Decisões sem evidências.	Algumas decisões citam métricas; falta desvio entre folds.	Decisões citam métricas com desvio; comparações pareadas presentes.	Toda decisão técnica é respaldada por evidência experimental coerente com o briefing.
Integridade do split treino e teste	2%	Teste tocado antes da fase final (zera o critério e penaliza Modeling).	-	-	Sem violação; sentinela presente; uso único do teste.
Apresentação final (15 minutos, divisão entre integrantes, clareza)	5%	Excede tempo, integrante ausente ou slides confusos.	Apresentação no tempo, mas com pouca ênfase em comparação.	Apresentação bem distribuída, foco em busca HP e comparação.	Apresentação polida, narrativa orientada ao cliente, leitura precisa de gráficos.

Tabela 1: Rubrica do projeto final. Pesos somam 100%. O critério de Integridade do split tem peso pequeno mas qualquer violação penaliza também os critérios de Modeling e Avaliação final no teste.

Notas operacionais

- A pontuação em cada critério resulta da multiplicação do peso pelo nível atingido (0,40; 0,70; 0,90; 1,00, conforme escala).
- Para os critérios de Modeling e Busca de hiperparâmetros, ausência de mais de um algoritmo penaliza um nível inteiro.
- Decisões que mostrem comparação com o baseline via teste pareado (Wilcoxon ou paired t-test) e curvas treino vs validação são requisitos para alcançar Bom ou Excelente nos critérios principais.

- Reprodutibilidade do repositório (notebook principal executando de ponta a ponta com poucos comandos) é pré-requisito para o nível Excelente em qualquer critério que dependa de evidência experimental.