

# Projeto Final - Mineração de Dados com CRISP-DM

Cliente: **[NOME DO CLIENTE]** | Dataset: **[NOME DO DATASET]**

Grupo: **[INTEGRANTES]**

IF1014 - CIn-UFPE - 2026.1

Apresentação em 27/05/2026

# Agenda

- Briefing do cliente (Business Understanding)
- Dataset e EDA (Data Understanding)
- Pré-processamento (Data Preparation)
- Modelagem e busca de hiperparâmetros
- Avaliação e comparação (baseline vs melhorias)
- Avaliação final no teste e Deployment
- Conclusões e próximos passos

# Business Understanding: cliente e problema

- **Cliente:** [nome fictício, setor]
- **Problema:** [tarefa de classificação multiclasse]
- **Classes:** [lista]
- **Métrica principal:** [F1-macro / balanced accuracy / etc.]
- **Restrições:** [latência, custo de erro, privacidade]
- **Riscos:** [viés, classes raras, impacto social]

- Fonte: [Kaggle / UCI / OpenML]
- Volume: [N linhas x M colunas]
- Classes: [k classes]
- Distribuição: [equilibrada / desbalanceada]

[gráfico de distribuição de classes]

# Data Understanding: três achados que orientaram o projeto

- ❶ Achado 1: [ex. classe X representa 60 por cento; classe Y, 5 por cento].
- ❷ Achado 2: [ex. correlação alta entre features A e B sugere redundância].
- ❸ Achado 3: [ex. faltantes concentrados em um subconjunto de colunas].

Esses achados motivaram as escolhas de métrica e de variantes (próximos slides).

# Data Preparation: pipeline baseline

- **Numéricas:** imputação por mediana.
- **Categóricas:** imputação por moda + OneHotEncoder.
- **Sem escala** no baseline (de propósito; isso entra como variante).
- **Sem balanceamento** no baseline (idem).

*Justificativa:* o baseline serve de ponto de comparação para medir o efeito de cada melhoria.

## Data Preparation: variantes do conjunto de treino

| Variante | Técnica                                | Hipótese                               |
|----------|----------------------------------------|----------------------------------------|
| v2       | [SMOTE / undersampling / class_weight] | [reduzir viés para classe minoritária] |
| v3       | [StandardScaler + Target Encoder]      | [favorecer SVM e MLP]                  |
| v4       | [PCA / interações / descarte]          | [reduzir ruído / colinearidade]        |

## Parte 1

- K-NN
- LVQ (skl`lvq`)
- Árvore de Decisão
- SVM
- Random Forest

## Parte 2

- MLP
- Comitê de RNAs
- Stacking heterogêneo
- XGBoost
- LightGBM



# Modeling: busca de hiperparâmetros (exemplo)

[curva treino vs validação do modelo X]

Trade-off entre viés e variância. Configuração escolhida marcada em vermelho.

# Modeling: melhores configurações (baseline)

| Modelo        | F1-macro (val)   | Configuração                       |
|---------------|------------------|------------------------------------|
| K-NN          | 0,xx $\pm$ 0,0xx | n_neighbors=..., weights=...       |
| LVQ           | 0,xx $\pm$ 0,0xx | ...                                |
| Árvore        | 0,xx $\pm$ 0,0xx | max_depth=..., criterion=...       |
| SVM           | 0,xx $\pm$ 0,0xx | C=..., kernel=..., gamma=...       |
| Random Forest | 0,xx $\pm$ 0,0xx | n_estimators=..., max_features=... |
| MLP           | 0,xx $\pm$ 0,0xx | hidden_layer_sizes=..., alpha=...  |
| Comitê RNAs   | 0,xx $\pm$ 0,0xx | n_estimators=..., base=...         |
| Stacking      | 0,xx $\pm$ 0,0xx | passthrough=..., final=...         |
| XGBoost       | 0,xx $\pm$ 0,0xx | n_estimators=..., lr=...           |
| LightGBM      | 0,xx $\pm$ 0,0xx | num_leaves=..., lr=...             |

[gráfico de barras: F1-macro de val por modelo]

Três modelos líderes: [modelo A], [modelo B], [modelo C]. Diferença aproximadamente [X] desvios.

# Evaluation: baseline vs melhorias (Wilcoxon pareado)

[gráfico de barras agrupado: baseline + variantes]

Variante com maior ganho consistente: [v\_X]. Modelos que ganharam significância ( $p < 0,05$ ): [lista].

# Evaluation: avaliação final no conjunto de teste

- **Modelo escolhido:** [nome] com [variante].
- **Configuração:** [hiperparâmetros].
- **F1-macro de validação (CV no treino):**  $[0,xx \pm 0,0xx]$ .
- **F1-macro no teste:**  $[0,xx]$ . Queda de [delta] vs CV.
- **AUC macro / AP macro:** [valores].

[matriz de confusão normalizada]

Classe [Y] tem o pior recall ([0,xx]). Implicação para o cliente: [comentário].

# Deployment: como o modelo seria usado

- **Forma de uso:** [API REST / batch diário / integração com sistema X]
- **Latência esperada:** [ms ou s por predição]
- **Riscos:** [concept drift, classes raras, custo desigual de erro]
- **Mitigações:** [thresholds por classe, calibração, retreino]
- **Monitoramento:** [F1-macro, drift de features, taxa de erro por classe]

- Atendemos o critério de sucesso: [F1 alvo era X; obtivemos Y].
- A combinação [variante + modelo] foi superior ao baseline com [significância estatística].

Projeto .



- **Limites:** [classes minoritárias com baixo recall, custo de fit alto, etc.]
- **Próximos passos:** [coletar mais dados, testar GBM com mais features, calibração]
- **Recomendação ao cliente:** [como integrar e quando retreinar]

## Perguntas?

Repositório: [link]

Contato: [emails dos integrantes]

Referências principais: [3 a 5 itens]